FANGNON ORNELLA | BACHELOR 2 DATA&BI

PROJET O.R.I.O.N

(**O**bservatoire des **R**éponses et **I**ndicateurs de l'**O**ctroi en **N**iveau d'asile)

NEXA Digital School

HCR / UNHCR — Département Data & Analyse stratégique — Bureau Europe

Période d'analyse : 2015–2023 | 29 pays d'accueil | 54 pays africains d'origine

SOMMAIRE

1. Contexte et objectifs stratégiques du projet3

1.1 Présentation de l'organisation3

1.2 Problématique du projet4

1.3 Objectifs stratégiques du projet4

Analyse SWOT — Diagnostic stratégique du projet5

2. Analyse des besoins et étude de faisabilité6

2.1 Identification des besoins6

2.1.1 Besoins fonctionnels6

2.1.2 Besoins en données7

2.2 Veille technologique8

2.3 Sources documentaires mobilisées (annexes)9

2.4 Priorisation des besoins — Méthode MoSCoW9

2.5 Étude de faisabilité10

2.5.1 Contraintes techniques10

2.5.2 Contraintes légales et éthiques11

DEUXIÈME PARTIE : LA CONCEPTION D'UNE SOLUTION12

a. Identification du jeu de données choisi12

Évaluation et sélection des sources de données12

Présentation détaillée des sources retenues13

*Dataset 1 — HCR : Décisions d'asile*13

*Dataset 2 — HCR : Demandes d'asile*14

*Dataset 3 — HCR : Personnes relevant du mandat*14

*Dataset 4 — Eurostat : PIB par habitant*14

*Dataset 5 — Eurostat : PIB total*15

*Dataset 6 — EM-DAT : Catastrophes et crises en Afrique*15

*Datasets partiellement utilisés*15

Qualité initiale des données16

Objectifs de nettoyage et d'analyse16

b. Préparation et nettoyage des données17

Pipeline de nettoyage — Phase 117

Analyse statistique et test des hypothèses — Phase 218

c. Analyse descriptive et modélisation19

c.1 Vue d'ensemble du dataset final19

c.2 Disparités entre pays d'accueil19

c.3 Résultats statistiques — test des quatre hypothèses20

*Hypothèse 1 — Volume de demandes et taux d'acceptation*20

*Hypothèse 2 — Pays d'origine en situation de crise*21

*Hypothèse 3 — Effet temporel*21

*Hypothèse 4 — Facteur économique*22

c.4 Tableau de synthèse des hypothèses22

d. Conclusions métiers23

Rappel de la problématique23

Réponse argumentée à la problématique23

Limites de l'analyse24

Pistes d'amélioration et de prolongement24

e. Retours, ajustements et organisation25

Retours obtenus et ajustements effectués25

Retours sur le jeu de données 25
Retours sur la modélisation 25
Retours sur la structure du code 26
Apprentissages acquis 26
Compétences techniques 26
Compétences métiers 27

Sources et références 27

Sources de données 27
Publications scientifiques et rapports institutionnels 28
Outils et environnement technique 28

Annexes 29

Annexe 1 Carammia et al. (2022) — Machine Learning et flux d'asile 29
Annexe 2 Eurostat — Migration and asylum in Europe, édition 2025 29
Annexe 3 Eurostat — Asylum decisions, annual statistics 2025 30
Annexe 4 JRC / Bosco (2024) — Forecasting migration flows 30
Annexe 5 Adenuga et al. (2025) — Dashboards BI dans le secteur public 30

1. Contexte et objectifs stratégiques du projet

1.1 Présentation de l'organisation

Le projet s'inscrit dans un contexte institutionnel fictif mais réaliste : celui du **Haut-Commissariat des Nations Unies pour les Réfugiés (HCR / UNHCR)**, et plus précisément au sein de son **département Data & Analyse stratégique – Bureau Europe**. Fondé en 1950, le HCR a pour mission principale la protection internationale des réfugiés, des demandeurs d'asile et des personnes déplacées à travers le monde.

Fiche d'identité institutionnelle	
Secteur	Organisation internationale humanitaire — Protection et coordination des politiques d'asile
Envergure	Présence dans plus de 130 pays, plus de 20 000 collaborateurs dans le monde
Périmètre	Coopération étroite avec les États membres de l'Union européenne
Valeurs	Protection des droits fondamentaux · Neutralité politique · Décisions fondées sur les données · Coopération internationale

En Europe, le HCR fait face à des enjeux majeurs : augmentation des flux migratoires en provenance d'Afrique, déséquilibre dans la répartition des demandeurs d'asile entre États membres, divergence des pratiques nationales d'acceptation et pression budgétaire croissante. Son **département Data & Innovation** est chargé de produire des analyses quantitatives rigoureuses pour éclairer la prise de décision stratégique.

1.2 Problématique du projet

Afin d'accompagner les États européens dans l'amélioration de leurs politiques d'accueil, le HCR cherche à mieux comprendre les disparités observées entre pays. La problématique centrale retenue est la suivante :

> ***“Pourquoi les taux d'acceptation des demandes d'asile africaines varient-ils entre les pays européens ? ”***

Cette question vise à produire une analyse explicative permettant de mieux orienter les recommandations politiques, d'améliorer la coordination européenne en matière d'asile et d'optimiser l'allocation des ressources humanitaires et financières.

1.3 Objectifs stratégiques du projet

Le projet data poursuit cinq objectifs stratégiques directement reliés aux priorités institutionnelles du HCR :

- **Identifier** les facteurs mesurables expliquant les écarts de taux d'acceptation entre États membres.
- **Produire** des indicateurs comparatifs permettant d'évaluer les pratiques nationales d'accueil.
- **Mettre en évidence** les tendances temporelles liées aux périodes de forte pression migratoire.
- **Aider à la planification** des ressources d'accueil et d'assistance à l'échelle européenne.
- **Fournir** une base analytique robuste pour les recommandations politiques européennes.

Analyse SWOT — Diagnostic stratégique du projet

L'analyse SWOT ci-dessous positionne le projet data au regard des enjeux internes et externes du HCR en Europe.

✚ Forces (Strengths)	▲ Faiblesses (Weaknesses)
• Légitimité institutionnelle reconnue par les États membres• Accès privilégié aux données Eurostat et aux bases nationales• Expertise analytique du département Data & Innovation• Neutralité politique facilitant la coopération des partenaires	• Hétérogénéité des méthodes de collecte selon les pays• Données parfois incomplètes ou non harmonisées• Ressources humaines limitées pour l'analyse avancée• Dépendance aux remontées d'information des États membres
◆ Opportunités (Opportunities)	**✕ Menaces (Threats)**
• Demande croissante des États pour des outils d'aide à la décision• Développement des capacités de data science au sein de l'UE• Agenda européen sur la migration favorable à la coopération• Potentiel de valorisation des résultats en recommandations politiques	• Sensibilité politique des données migratoires en période électorale• Risque de biais dans les bases de données nationales• Évolution rapide des flux rendant les analyses rapidement obsolètes• Résistance de certains États à partager leurs données d'asile

Cette analyse met en évidence la **position stratégique favorable** du HCR pour mener ce projet : la légitimité institutionnelle et l'accès aux données constituent des atouts différenciants, tandis que l'harmonisation des sources et la gestion de la sensibilité politique représentent les principaux défis à anticiper dans la démarche analytique.

2. Analyse des besoins et étude de faisabilité

2.1 Identification des besoins

2.1.1 Besoins fonctionnels

Les besoins fonctionnels décrivent ce que la solution data doit permettre de réaliser concrètement, en réponse à la problématique posée.

BF-01 — Collecte et consolidation des données

La solution doit permettre d'importer, de centraliser et de consolider les données issues de sources hétérogènes (Eurostat, UNHCR, Banque mondiale, ACLED) dans un environnement de travail unifié.

BF-02 — Nettoyage et préparation des données

La solution doit permettre d'identifier et de traiter les valeurs manquantes, les doublons, les incohérences de format et les anomalies statistiques, afin de garantir la fiabilité des analyses.

BF-03 — Analyse statistique descriptive et comparative

La solution doit permettre de calculer des indicateurs synthétiques (taux d'acceptation par pays, par nationalité, par période), de produire des distributions statistiques, des corrélations et des comparaisons entre États membres.

BF-04 — Test des hypothèses de recherche

La solution doit permettre de tester les quatre hypothèses définies (volume, conflit, temporalité, facteur économique) à partir d'outils statistiques adaptés (corrélations, régressions, tests de significativité).

BF-05 — Visualisation et restitution

La solution doit permettre de produire des visualisations lisibles et exportables (graphiques, cartes, tableaux de bord) destinées à des audiences non techniques : décideurs politiques, équipes opérationnelles du HCR.

BF-06 — Génération de recommandations

À partir des résultats analytiques, la solution doit permettre de formuler des recommandations opérationnelles structurées, directement exploitables dans le cadre des politiques européennes d'asile.

2.1.2 Besoins en données

Dimension	Détail
Sources principales	Eurostat (base migr_asydcfsta), UNHCR Population Data, Banque mondiale (PIB, chômage, IDH), ACLED (conflits armés en Afrique)
Périmètre géographique	27 États membres de l'UE + Norvège, Suisse
Périmètre temporel	2015–2023 (couvrant la crise syrienne, le pic africain 2017-2019, la période Covid, la reprise 2021-2023)
Granularité	Annuelle, par pays d'accueil, par pays d'origine africain
Variables clés	Taux d'acceptation en 1re instance, nombre de demandes déposées, pays d'origine, statut accordé (réfugié / protection subsidiaire / humanitaire), PIB par habitant, taux de chômage, indice de conflit ACLED
Format attendu	Fichiers CSV / XLSX structurés, accessibles via API Eurostat ou téléchargement direct
Qualité attendue	Données officielles, mises à jour annuellement, avec documentation des métadonnées
Risques identifiés	Données manquantes pour certains petits États membres ; hétérogénéité des définitions nationales de "protection humanitaire" ; délais de publication Eurostat

À titre de contexte, en 2024, les pays de l'UE ont accordé un statut de protection à **437 900 demandeurs d'asile**, soit une hausse de 6,9 % par rapport à 2023, confirmant l'importance et la richesse des données disponibles via Eurostat pour ce type d'analyse *(Eurostat, Asylum decisions – annual statistics, 2025).*.

2.2 Veille technologique

La veille technologique vise à identifier les tendances pertinentes du secteur data susceptibles d'enrichir et de crédibiliser la démarche analytique de ce projet.

Tendance 1 — Machine Learning appliqué à la prévision des flux migratoires

L'utilisation d'algorithmes de machine learning pour analyser et prévoir les dynamiques migratoires constitue une tendance de fond dans la recherche académique et institutionnelle. Des chercheurs de l'EUAA, de la Commission européenne (JRC) et de l'Université de Catane ont développé **un algorithme adaptatif intégrant des statistiques administratives et des sources de données non traditionnelles**, afin de prévoir efficacement les flux d'asile. Publiée dans *Nature Scientific Reports* (Carammia et al., 2022), cette étude démontre que la combinaison de données officielles avec des données non conventionnelles améliore significativement la précision des prévisions.

> *Pertinence pour le projet : Bien que notre projet se concentre sur l'analyse explicative et non prédictive, cette tendance valide l'intérêt de croiser des variables macro-économiques, sécuritaires et institutionnelles. Elle justifie l'intégration de variables relatives aux conflits africains (données ACLED) dans notre modèle d'analyse pour tester l'hypothèse H2.*

Source [1] : Carammia, M., Iacus, S. M., & Super, L. (2022). Forecasting asylum-related migration flows with machine learning and data at scale. Scientific Reports, 12(1), 1568. https://www.nature.com/articles/s41598-022-05241-8

Tendance 2 — Démocratisation des outils BI pour la décision dans le secteur public

Les outils de Business Intelligence (BI) — tels que Power BI ou Tableau — s'imposent progressivement dans les organisations publiques et humanitaires comme instruments de pilotage analytique. Pour les entités du secteur public, **l'intégration de tableaux de bord en temps réel se traduit par des capacités de réponse rapide lors de situations d'urgence**, notamment pour suivre l'impact de crises ou surveiller l'efficacité des politiques publiques (Adenuga et al., 2025). Cette tendance s'accompagne d'une montée en puissance des outils open source Python (Plotly, Dash, Seaborn) qui permettent de produire des visualisations de qualité professionnelle sans coût de licence.

> *Pertinence pour le projet : La restitution des analyses sous forme de visualisations exportables est une exigence clé du projet. L'utilisation de Python (matplotlib, seaborn, plotly) répond à cette tendance en rendant les résultats intelligibles pour des audiences décisionnelles non techniques au sein du HCR et des États membres.*

Source [2] : Adenuga et al. (2025). Real-Time Analytics Dashboards for Decision-Making Using Tableau in Public Sector and Business Intelligence Applications. ResearchGate. https://www.researchgate.net/publication/393907578

2.4 Priorisation des besoins — Méthode MoSCoW

La méthode **MoSCoW** (Must have / Should have / Could have / Won't have) permet de hiérarchiser les besoins fonctionnels et de données en fonction de leur caractère critique pour atteindre les objectifs du projet.

Priorité	Besoin identifié	Justification
MUST	Collecte des données Eurostat (taux d'acceptation, volumes, pays d'origine)	*Constitue le cœur du dataset sans lequel aucune analyse n'est possible*
MUST	Nettoyage et standardisation des données (BF-02)	*Condition sine qua non de la fiabilité des résultats*
MUST	Analyse descriptive comparative par pays (BF-03)	*Répond directement à la problématique centrale du projet*
MUST	Test des 4 hypothèses de recherche (BF-04)	*Objectif analytique principal du projet*
MUST	Intégration des données de conflits africains (ACLED)	*Nécessaire pour tester l'hypothèse H2 (pays d'origine en conflit)*
SHOULD	Visualisations exportables (graphiques, cartes choroplèthes)	*Fortement recommandé pour la restitution aux décideurs politiques*
SHOULD	Intégration des indicateurs économiques (PIB, chômage, IDH)	*Nécessaire pour tester l'hypothèse H4 (facteur économique)*
SHOULD	Analyse de séries temporelles 2015–2023	*Nécessaire pour tester l'hypothèse H3 (effet temporel)*

COULD	Tableau de bord interactif (Plotly / Dash)	*Valeur ajoutée pour la présentation finale, mais non indispensable*
COULD	Modèle de régression multiple explicatif	*Enrichissement analytique possible si le temps le permet*
WON'T	Modèle prédictif de flux migratoires futurs	*Hors périmètre du projet (analyse explicative uniquement)*
WON'T	Intégration de données en temps réel via API dynamique	*Complexité technique disproportionnée par rapport aux objectifs*

2.5 Étude de faisabilité

2.5.1 Contraintes techniques

Dimension	Évaluation	Niveau de risque
Outils disponibles	Python (pandas, numpy, matplotlib, seaborn, scipy, plotly), Jupyter Notebook, Excel. Tous open source ou accessibles sans coût.	**Faible**
Disponibilité des données	Données Eurostat accessibles librement via portail en ligne et API REST. Données ACLED et Banque mondiale disponibles gratuitement avec inscription.	**Faible**
Compétences requises	Maîtrise de Python niveau intermédiaire, statistiques descriptives, notions de régression. Compétences disponibles dans l'équipe projet.	**Modéré**
Volume de données	Données tabulaires de taille raisonnable (quelques dizaines de milliers de lignes). Aucun besoin de Big Data ou d'infrastructure lourde.	**Faible**
Temps de réalisation	Le périmètre est adapté à un projet académique de 3 à 4 mois. Les tâches critiques (collecte, nettoyage, analyse) sont séquentielles et planifiables.	**Modéré**
Harmonisation des sources	Principale difficulté technique : alignement des nomenclatures entre Eurostat, ACLED et Banque mondiale (pays, années, définitions variables).	**Élevé**

2.5.2 Contraintes légales et éthiques

Conformité RGPD

Le Règlement Général sur la Protection des Données (RGPD, UE 2016/679) s'applique à tout traitement de données à caractère personnel au sein de l'Union européenne. Dans le cadre de ce projet, les données utilisées sont exclusivement des **statistiques agrégées publiées par des institutions officielles** (Eurostat, UNHCR, Banque mondiale). Aucune donnée nominative, aucun identifiant individuel, aucune donnée sensible au sens de l'article 9 du RGPD n'est traitée. **Le projet est donc en conformité pleine avec le RGPD.**

Éthique et neutralité analytique

Les données relatives à l'asile sont politiquement sensibles. Le projet s'inscrit dans une démarche de stricte neutralité analytique, sans visée normative sur les politiques nationales. Conformément aux valeurs institutionnelles du HCR, les résultats ne doivent en aucun cas contribuer à stigmatiser des nationalités ou des groupes de population. Ils seront systématiquement accompagnés de leurs limites méthodologiques.

Propriété intellectuelle

L'ensemble des sources de données mobilisées sont placées sous licences ouvertes (Creative Commons, Open Data Eurostat). Leur réutilisation à des fins analytiques et académiques est explicitement autorisée, sous réserve de citation des sources.

Contrainte légale	Statut	Action requise
RGPD — données personnelles	☑ **Conforme**	Aucune (données agrégées uniquement)
Licences des données sources	☑ **Conforme**	Citation obligatoire des sources
Neutralité analytique	☑ **Respectée**	Contextualisation des résultats
Sécurité des données	☑ **Faible risque**	Aucune mesure spécifique requise

> *Conclusion sur la faisabilité : Le projet présente un niveau de faisabilité globalement élevé. Les données sont accessibles, les outils disponibles et la conformité réglementaire assurée. Le principal risque opérationnel réside dans l'harmonisation des nomenclatures entre sources, qui devra faire l'objet d'une attention particulière en phase de préparation des données.*

DEUXIÈME PARTIE : LA CONCEPTION D'UNE SOLUTION

a. Identification du jeu de données choisi

La conception de la solution analytique repose sur la constitution d'un **jeu de données composite et multi-sources**, assemblé à partir de neuf fichiers fournis et évalués ci-après. Cette section présente l'ensemble des sources examinées, leur adéquation au projet, leur qualité initiale, ainsi que les objectifs de nettoyage et d'analyse retenus pour la phase de traitement sous ***VSCode / Jupyter Notebook***.

1. Évaluation et sélection des sources de données

Neuf fichiers ont été analysés. Le tableau ci-dessous présente leur évaluation systématique selon leur pertinence, leur qualité et leur décision de rétention dans le projet.

Fichier / Source	Type	Lignes	Qualité	Décision
HCR — Décisions d'asile	CSV (ZIP)	112 498	**Haute**	☑ **Retenu**
HCR — Demandes d'asile	CSV (ZIP)	119 139	**Haute**	☑ **Retenu**
HCR — Chiffres population	CSV (ZIP)	138 226	**Haute**	☑ **Retenu**
Eurostat — PIB par habitant	CSV (GZ)	31 303	**Haute**	☑ **Retenu**
Eurostat — PIB total (volumes)	CSV (GZ)	4 151	**Bonne**	☑ **Retenu**
Eurostat — Protection sociale	CSV (GZ)	25 052	**Bonne**	⚠ **Partiel**

Eurostat — Taux de chômage	CSV (GZ)	100 315	**Moyenne**	⚠ **Partiel**
Eurostat — Taux d'emploi	CSV (GZ)	121 785	**Moyenne**	⚠ **Partiel**
EM-DAT — Catastrophes naturelles	XLSX	16 692	**Haute**	☑ **Retenu**

2. Présentation détaillée des sources retenues

Dataset 1 — HCR Refugee Data Finder : Décisions d'asile

asylum_decisions.csv	
Source officielle	UNHCR Refugee Data Finder (data.unhcr.org) — données institutionnelles mondiales
Format / Taille	CSV compressé (ZIP) — 112 498 lignes × 13 colonnes — mise à jour : février 2026
Couverture	2000–2025, tous pays du monde (pays d'asile × pays d'origine)
Variables clés	Year, Country of Asylum, Country of Origin, Dec recognized, dec rejected, dec other, dec closed, dec total, Procedure Type, Dec level
Pertinence projet	SOURCE CENTRALE. Permet de calculer le taux d'acceptation = Dec recognized / dec total, par pays européen d'accueil et par pays d'origine africain
Points forts	Données officielles UNHCR, couverture mondiale exhaustive, granularité pays-à-pays, historique long (25 ans)

Dataset 2 — HCR Refugee Data Finder : Demandes d'asile

asylum_applications.csv	
Source officielle	UNHCR Refugee Data Finder (data.unhcr.org)
Format / Taille	CSV compressé (ZIP) — 119 139 lignes × 10 colonnes — mise à jour : février 2026
Couverture	2000–2025, tous pays du monde
Variables clés	Year, Country of Asylum, Country of Origin, Applied, Procedure Type, Application type, Decision level
Pertinence projet	Complète le Dataset 1 : permet d'analyser le volume de demandes déposées (hypothèse H1) et de distinguer premières demandes et renouvellements
Points forts	Même source que DS1, cohérence assurée ; permet de croiser demandes et décisions sur la même période

Dataset 3 — HCR Refugee Data Finder : Personnes relevant du mandat

persons_of_concern.csv	

Source officielle	UNHCR Refugee Data Finder (data.unhcr.org)
Format / Taille	CSV compressé (ZIP) — 138 226 lignes × 11 colonnes — mise à jour : février 2026
Couverture	1951–2025 (historique complet)
Variables clés	Year, Country of Asylum, Country of Origin, Refugees, Asylum-seekers, IDPs, Stateless persons
Pertinence projet	Fournit le stock de réfugiés reconnus par pays d'accueil pour contextualiser la pression migratoire cumulée ; complète l'analyse H1 et H3
Points forts	Historique exceptionnel depuis 1951 ; permet d'analyser la pression cumulative sur les systèmes d'accueil

Dataset 4 — Eurostat : PIB par habitant

NAMA_10_PC — PIB par habitant (EUR/habitant)	
Source officielle	Eurostat, Commission européenne (ec.europa.eu/eurostat)
Format / Taille	CSV compressé (GZ) — 31 303 lignes × 18 colonnes
Couverture	1995–2025, tous pays européens (EU27 + Suisse, Norvège, etc.)
Variables clés	geo (code pays), TIME_PERIOD (année), OBS_VALUE (PIB/hab en EUR courants)
Pertinence projet	VARIABLE CLÉ pour l'hypothèse H4 (facteur économique). Indicateur de richesse nationale directement comparable entre États membres
Points forts	Source officielle de référence, données harmonisées UE, couverture temporelle complète sur la période d'étude 2015–2023

Dataset 5 — Eurostat : PIB total (volumes chaînés)

NAMA_10_GDP — PIB total en volumes chaînés (2010)	
Source officielle	Eurostat, Commission européenne
Format / Taille	CSV compressé (GZ) — 4 151 lignes × 18 colonnes
Couverture	1995–2025, pays européens
Variables clés	geo, TIME_PERIOD, OBS_VALUE (PIB en millions EUR, volumes chaînés 2010)
Pertinence projet	Complète le DS4 pour analyser la taille absolue de l'économie d'accueil ; utile pour normaliser les ressources disponibles par habitant
Points forts	Volumes chaînés permettent les comparaisons en termes réels, sans effet inflation

Dataset 6 — EM-DAT : Catastrophes et crises en Afrique

EM-DAT (CRED) — Base mondiale des catastrophes naturelles et technologiques	
Source officielle	Centre for Research on the Epidemiology of Disasters (CRED), Université catholique de Louvain — emdat.be
Format / Taille	XLSX — 16 692 lignes × 47 colonnes (dont ~4 284 concernant l'Afrique)
Couverture	2000–2026, monde entier (filtre Afrique appliqué dans le projet)
Variables clés	ISO (pays), Country, Region, Subregion, Disaster Type, Start Year, Total Deaths, No. Affected, Total Damage
Pertinence projet	Proxy de déstabilisation dans les pays africains d'origine : épidémies, sécheresses, inondations majeures, crises industrielles — vient compléter l'indicateur de conflits pour l'hypothèse H2
Points forts	Seule base mondiale à couvrir tous types de catastrophes avec données quantitatives (morts, déplacés, dommages) ; reconnue par l'ONU

Datasets partiellement utilisés (traitement conditionnel)

Fichier	Raison du traitement partiel	Usage conditionnel
Eurostat — Protection sociale (SPR_EXP_TYPE)	Couvre les dépenses sociales (€/hab) mais ne débute qu'en 2018 pour la plupart des pays. Couverture temporelle insuffisante pour la période 2015–2023.	*Utilisé uniquement pour la période 2018–2023 si l'hypothèse H4 nécessite un indicateur de générosité du système d'accueil*
Eurostat — Taux chômage (LFSA_URGANEDM)	Données disponibles uniquement à partir de 2021. Ventilées par statut migratoire et niveau de diplôme, ce qui génère un volume très élevé (100k lignes) avec beaucoup de valeurs manquantes.	*Filtrage sur citoyenneté TOTAL et sexe TOTAL ; usage limité aux années 2021–2023 pour analyse complémentaire H4*
Eurostat — Taux emploi (LFSA_ERGANEDM)	Même structure et mêmes limites que le taux de chômage. Forte granularité qui génère redondance avec le fichier chômage.	*Sera agrégé avec le fichier chômage si les données se révèlent complémentaires*

3. Qualité initiale des données

L'analyse exploratoire des fichiers révèle plusieurs enjeux de qualité à traiter en phase de nettoyage.

Problème identifié	Datasets concernés	Action de nettoyage prévue
Valeurs manquantes (NaN / vides)	HCR décisions (dec other, dec closed) ; Eurostat PIB (années récentes)	Imputation par 0 pour les colonnes de décompte ; exclusion des années incomplètes

Hétérogénéité des noms de pays	HCR (noms complets en anglais) vs Eurostat (codes ISO-2)	Création d'une table de correspondance pays → ISO-3 → ISO-2
Granularité excessive	Taux chômage / emploi (ventilation par diplôme, sexe, citoyenneté)	Agrégation sur TOTAL sexe + TOTAL citoyenneté
Doublons potentiels	HCR applications (procédures multiples par dyade pays-année)	Dédoublonnage sur Year + Country of Asylum + Country of Origin + Procedure Type
Flags de fiabilité	Eurostat (flags 'bu', 'u', 'p' = provisional, low reliability)	Exclusion des valeurs flaggées 'u' (faible fiabilité) ; signalement des valeurs 'p'
Périmètre temporel non uniforme	Taux chômage : 2021–2024 seulement ; Protection sociale : 2018+	Restriction du jeu de données principal à 2015–2023 ; variables secondaires 2018–2023

4. Objectifs de nettoyage et d'analyse

Phase 1 — Préparation et nettoyage (VSCode / Jupyter Notebook)

- **Étape 1 :** Charger et explorer chaque fichier avec pandas (shape, dtypes, valeurs manquantes, doublons).
- **Étape 2 :** Filtrer les données sur le périmètre du projet : pays européens d'accueil (EU27 + NO, CH), pays d'origine africains, années 2015–2023.
- **Étape 3 :** Harmoniser les référentiels géographiques via une table de correspondance pays (nom anglais → code ISO-3 → code ISO-2).
- **Étape 4 :** Calculer la variable cible : taux d'acceptation = décisions positives / total décisions, par pays × année × origine.
- **Étape 5 :** Fusionner les datasets en un DataFrame analytique unique (merge sur clé pays-d'accueil + année).

Phase 2 — Analyse statistique et test des hypothèses

- **H1 (volume) :** Statistiques descriptives : distributions des taux d'acceptation, carte choroplèthe par pays européen. Corrélation entre taux d'acceptation et volume annuel de demandes reçues par pays.
- **H2 (conflit) :** Croisement avec l'indice EM-DAT (nombre d'évènements, décès) par pays africain d'origine. Comparaison des taux d'acceptation entre pays africains en crise vs pays stables.
- **H3 (temporel) :** Analyse des séries temporelles ; test de variation des taux sur les années de pic migratoire (2015-2016, 2022-2023).
- **H4 (économique) :** Corrélation entre PIB/habitant des pays d'accueil et taux d'acceptation moyen ; régression simple.

> *Synthèse du jeu de données final : 6 sources retenues (3 HCR + 2 Eurostat économiques + 1 EM-DAT), 3 sources partielles selon disponibilité temporelle. Le jeu de données consolidé couvre la période 2015–2023, pour 27+ pays européens d'accueil et l'ensemble des pays africains d'origine. L'environnement de*

> *travail retenu est VSCode avec Jupyter Notebook et la stack Python (pandas, numpy, matplotlib, seaborn, scipy, plotly).*

b. Préparation et nettoyage des données

La phase de préparation constitue le socle technique du projet. Elle couvre l'ensemble des opérations de chargement, d'exploration, de nettoyage, de transformation et de fusion des données sources. Toutes ces étapes ont été réalisées dans un notebook Jupyter unique (*analyse_hcr.ipynb*) sous VSCode, dans un environnement Python isolé via environnement virtuel.

Pipeline de nettoyage — Phase 1

Le pipeline de nettoyage suit une séquence rigoureuse en cinq étapes. Les fichiers sources sont lus directement depuis leurs formats compressés natifs (ZIP et GZ) sans extraction sur disque, ce qui garantit la reproductibilité de l'environnement.

- **Chargement des fichiers bruts :** Lecture des archives ZIP (fichiers HCR) et GZ (fichiers Eurostat) via les modules zipfile et gzip de Python. Lecture du fichier XLSX EM-DAT via openpyxl. Affichage des dimensions et types de chaque dataset.
- **Filtres et périmètre :** Application des filtres définissant le périmètre analytique : années 2015–2023, pays d'accueil EU27 + Norvège + Suisse (codes ISO-3), pays d'origine africains (54 pays), décisions de première instance (Dec level = 'FI'), procédure générale (Procedure Type = 'G'), exclusion des lignes avec dec_total = 0.
- **Renommage et harmonisation :** Renommage des colonnes pour uniformiser les noms entre sources. Construction de la table de correspondance ISO-3 → ISO-2 avec traitement spécifique de la Grèce (codée 'EL' dans Eurostat au lieu de 'GR'). Nettoyage du nom 'Netherlands (Kingdom of the)' → 'Netherlands'.
- **Calcul de la variable cible :** Calcul du taux d'acceptation pondéré : taux = (sum décisions positives / sum décisions totales) × 100, par dyade pays d'accueil × pays d'origine × année. Cette formule évite le biais de la moyenne arithmétique des taux individuels qui surpondère les dyades à faible volume.
- **Export intermédiaire :** Sauvegarde des tables nettoyées en CSV et chargement dans une base SQLite (hcr.db) pour les requêtes SQL.

Analyse statistique et test des hypothèses — Phase 2

La phase d'analyse s'appuie sur le dataset final consolidé (4 867 lignes × 15 colonnes) produit par la fusion des tables nettoyées. Cinq requêtes SQL préparatoires ont été exécutées pour vérifier la cohérence des jointures avant les analyses Python. Le test des hypothèses repose sur des corrélations de Pearson et Spearman (scipy.stats), des agrégations pondérées par le volume et des visualisations matplotlib/seaborn.

c. Analyse descriptive et modélisation

c.1 Vue d'ensemble du dataset final

L'analyse porte sur un dataset consolidé de **4 867 combinaisons** pays d'accueil × pays d'origine africain × année, issu de la fusion de six sources officielles. Au total, **1 239 953 décisions de première instance** ont été analysées sur la période 2015–2023, pour 29 pays européens d'accueil et 54 pays africains d'origine.

Indicateur	Valeur	Commentaire

Taux d'acceptation moyen	19,5 %	*Moyenne pondérée, toute la période*
Écart-type du taux	26,7 pts	*Forte dispersion entre pays et origines*
Taux minimum	0,0 % (Lettonie, Slovaquie)	*Aucune décision positive*
Taux maximum	61,2 % (Norvège)	*Pays le plus accueillant*
Médiane du taux (dyades)	0,0 %	*Plus de la moitié des dyades à 0%*
Nombre de pays d'accueil	29 (EU27 + NO + CH)	*Périmètre complet*
Nombre de pays africains	54	*Couverture continentale*

La forte valeur de l'écart-type (26,7 points) traduit une hétérogénéité considérable des pratiques nationales. La médiane à 0 % révèle que la majorité des dyades pays–année présentent un taux nul, ce qui s'explique par le fait que certains pays européens refusent systématiquement les demandes de certaines nationalités africaines.

c.2 Disparités entre pays d'accueil

La visualisation du taux d'acceptation moyen par pays d'accueil (2015–2023) met en évidence trois groupes distincts.

Groupe	Pays	Taux moyen
Pays très accueillants	Norvège, Danemark, Luxembourg, Belgique, Pays-Bas	**39 % à 61 %**
Pays intermédiaires	Suède, Finlande, Suisse, Allemagne, Grèce, Irlande, France	**20 % à 38 %**
Pays très restrictifs	Italie, Pologne, Croatie, Hongrie, Bulgarie, Slovénie, Lettonie, Slovaquie	**0 % à 7 %**

Cet écart de **61,2 points entre le pays le plus accueillant (Norvège) et les pays les plus restrictifs** confirme une absence de convergence des pratiques nationales en matière d'asile, malgré le Régime d'Asile Européen Commun (RAEC). La France, premier pays de destination en volume (377 622 décisions), affiche un taux de 20,8 %, soit trois fois moins que la Norvège avec des volumes bien moindres.

c.3 Résultats statistiques — test des quatre hypothèses

Hypothèse 1 — Volume de demandes et taux d'acceptation

La corrélation de Pearson entre le volume annuel de demandes reçues par pays et son taux d'acceptation est de **r = 0,022 (p = 0,739)**. Ce résultat est statistiquement non significatif et quasi nul, ce qui invalide l'hypothèse. Le volume de demandes reçues n'exerce aucune pression mesurable sur la sélectivité des décisions. La France, avec plus de 33 000 demandes africaines en 2021, maintient un taux stable autour de 20 %, identique à des pays recevant dix fois moins de demandes.

Hypothèse 2 — Pays d'origine en situation de crise

La corrélation entre le nombre de catastrophes recensées dans le pays d'origine (EM-DAT) et le taux d'acceptation est de **r = –0,016 (p = 0,731)**. Statistiquement, la relation est non significative. Cependant, l'analyse qualitative montre que les pays africains les plus déstabilisés obtiennent systématiquement les taux les plus élevés en Europe :

Pays d'origine	Taux d'acceptation	Décisions totales	Moy. catastrophes/an
Érythrée	**66,8 %**	126 203	0,1
Burundi	**57,8 %**	9 556	2,1
Soudan	**41,3 %**	47 768	2,8
Rép. Centrafricaine	**41,2 %**	7 240	1,9
Soudan du Sud	**39,7 %**	1 205	2,0
Somalie	**32,2 %**	88 068	3,2

La limite principale de ce test est l'inadéquation de l'indicateur utilisé : EM-DAT recense les catastrophes naturelles et technologiques, mais **pas les conflits armés et persécutions politiques**, qui constituent la principale raison de fuite pour les demandeurs africains.

Hypothèse 3 — Effet temporel

L'analyse de l'évolution annuelle révèle des variations significatives du taux d'acceptation moyen sur la période. Le taux passe de **24,3 % en 2015 à 18,0 % en 2016**, soit une chute de 6,2 points coïncidant avec le pic migratoire européen lié à la crise syrienne et à l'intensification des flux africains. Il atteint son plancher en 2018 à **16,1 %**, avant de remonter progressivement jusqu'à **21,4 % en 2023**. L'écart total sur la période est de 8,2 points, ce qui confirme que les politiques d'asile réagissent aux contextes de pression migratoire.

Hypothèse 4 — Facteur économique

La corrélation entre le PIB par habitant moyen des pays d'accueil et leur taux d'acceptation est de **r = 0,754 (Pearson) et r = 0,732 (Spearman)**, avec $p < 0,001$ dans les deux cas. Il s'agit du résultat le plus solide de l'analyse. En divisant les pays en trois groupes égaux selon leur PIB :

Groupe PIB	Pays représentatifs	Taux moyen
PIB élevé	Norvège (61,2%), Danemark (58,2%), Luxembourg (55,8%)	**40,2 %**
PIB moyen	France (20,8%), Allemagne (25,6%), Irlande (23,9%)	**12,5 %**
Faible PIB	Pologne (6,3%), Bulgarie (1,4%), Lettonie (0,0%)	**8,9 %**

L'écart de **31,3 points entre le groupe le plus riche et le groupe le moins riche** confirme que le niveau de développement économique du pays d'accueil est le facteur explicatif le plus déterminant des disparités observées.

c.4 Tableau de synthèse des hypothèses

H	Énoncé	Statistique	Verdict
H1	Volume élevé → taux plus faible	r = 0,022 (p = 0,739)	❌ INFIRMÉE
H2	Pays en crise → taux plus élevé	r = –0,016 (p = 0,731)	⚠ PARTIELLE
H3	Taux varient selon les périodes	Écart 8,2 pts (2015–2023)	☑ CONFIRMÉE
H4	PIB élevé → taux plus élevé	r = 0,754 (p < 0,001)	☑ CONFIRMÉE

d. Conclusions métiers

Rappel de la problématique

Ce projet visait à répondre à la question suivante : **Pourquoi les taux d'acceptation des demandes d'asile africaines varient-ils entre les pays européens ?** Cette problématique s'inscrit dans la mission analytique du département Data & Innovation du HCR, dont l'objectif est d'éclairer les politiques d'asile européennes par des données chiffrées et comparatives.

Réponse argumentée à la problématique

L'analyse de 1 239 953 décisions de première instance sur neuf années permet d'apporter une réponse structurée. Les disparités entre pays européens — de 0 % en Lettonie à 61 % en Norvège — s'expliquent par deux facteurs principaux.

Le premier, et le plus déterminant, est **le niveau économique du pays d'accueil (H4)**. La corrélation entre le PIB par habitant et le taux d'acceptation est forte (r = 0,754) et robuste (confirmée par Spearman, r = 0,732). Les pays à PIB élevé acceptent en moyenne 40,2 % des demandes africaines, contre 8,9 % pour les pays à faible PIB. Cet écart de 31 points suggère que les capacités économiques d'accueil — logement, emploi, services sociaux — conditionnent directement les décisions politiques en matière d'asile.

Le second facteur est **l'effet des crises migratoires sur les politiques nationales (H3)**. La chute du taux moyen de 6,2 points entre 2015 et 2016 montre que les périodes de forte pression conduisent à un resserrement des critères d'acceptation, vraisemblablement sous l'effet de contraintes politiques internes. La remontée progressive de 5,3 points entre 2018 et 2023 témoigne d'une normalisation après la crise.

Les deux autres facteurs testés n'ont pas fourni les résultats attendus. **Le volume de demandes reçues (H1)** n'a aucun effet mesurable sur le taux (r = 0,022), ce qui invalide l'idée d'un « effet de saturation ». **La situation de crise dans le pays d'origine (H2)** influence qualitativement les décisions — les demandeurs érythréens (66,8 %), soudanais (41,3 %) et somaliens (32,2 %) obtiennent des taux bien au-dessus de la moyenne — mais l'indicateur EM-DAT utilisé ne capture pas les conflits armés, limitant la portée statistique du test.

Limites de l'analyse

- **Indicateur de crise insuffisant :** Les données EM-DAT ne couvrent pas les conflits armés et persécutions politiques, principale raison de fuite. H2 est donc sous-estimée.
- **Première instance uniquement :** L'analyse se limite aux décisions de première instance. Les taux finaux, après recours, peuvent être sensiblement différents.
- **Hétérogénéité des définitions :** La notion de « protection humanitaire » n'est pas définie de manière identique dans tous les pays membres, ce qui biaise les comparaisons directes.

- **Corrélation ≠ causalité :** Une corrélation élevée entre PIB et taux (r = 0,754) ne prouve pas que la richesse cause l'acceptation. D'autres facteurs comme les traditions juridiques, les politiques de gouvernement ou les accords bilatéraux pourraient expliquer une partie des écarts.

Pistes d'amélioration et de prolongement

- **Données ACLED :** Intégrer les données ACLED (Armed Conflict Location & Event Data) pour mesurer l'intensité des conflits armés dans les pays d'origine et améliorer le test de H2.
- **Indice MIPEX :** Ajouter un indice de politique migratoire (MIPEX) par pays et par année pour capturer les orientations politiques nationales au-delà du seul facteur économique.
- **Régression multiple :** Réaliser une régression multiple (taux ~ PIB + période + crise + volume) pour quantifier la contribution relative de chaque facteur et contrôler les effets de confusion.
- **Décisions en appel :** Inclure les décisions en appel pour obtenir les taux finaux réels, plus représentatifs de la protection accordée in fine.
- **Élargissement géographique :** Étendre l'analyse à d'autres continents d'origine (Asie, Moyen-Orient) pour vérifier si les facteurs identifiés sont universels ou spécifiques aux flux africains.

e. Retours, ajustements et organisation

Retours obtenus et ajustements effectués

Retours sur le jeu de données

Lors de la phase de conception, le premier jeu de données envisagé reposait uniquement sur les fichiers Eurostat, dont la couverture est limitée aux pays membres de l'UE et ne permettait pas d'identifier les pays d'origine africains avec la précision nécessaire. Sur recommandation du tuteur, les fichiers HCR (UNHCR Refugee Data Finder) ont été intégrés comme source principale, offrant une granularité pays d'accueil × pays d'origine × année introuvable dans les bases Eurostat.

Concernant l'indicateur de crise (H2), le premier choix s'était porté sur un index de conflit construit manuellement à partir de sources web. Ce choix a été abandonné au profit de la base EM-DAT, plus fiable et traçable. Cependant, l'analyse a mis en évidence la limite principale d'EM-DAT : l'absence de données sur les conflits armés. Une prochaine itération devra intégrer les données ACLED pour corriger ce biais.

Retours sur la modélisation

Le calcul initial du taux d'acceptation utilisait la moyenne arithmétique des taux individuels, ce qui surpondérait les dyades avec peu de décisions. Ce choix a été corrigé en adoptant un **taux pondéré par le volume** : sum(décisions positives) / sum(décisions totales) × 100. Cette correction a significativement modifié les résultats agrégés par pays, la médiane glissant vers des valeurs plus réalistes.

La première version du test H2 utilisait uniquement la corrélation de Pearson, sensible aux valeurs extrêmes. Le passage à une double validation Pearson + Spearman sur H4, suggéré lors d'une revue de mi-projet, a permis de confirmer la robustesse du résultat économique et de détecter que la relation PIB–taux est plus de rang que strictement linéaire.

Retours sur la structure du code

La version initiale du projet comportait deux notebooks séparés (un pour le nettoyage, un pour l'analyse), ce qui rendait difficile la reproduction des résultats. Sur retour d'un pair, le projet a été restructuré en **un seul notebook séquentiel**, accompagné d'un fichier SQL indépendant. Cette organisation permet à n'importe quel lecteur de suivre le pipeline de bout en bout sans dépendances entre fichiers.

Apprentissages acquis

Compétences techniques

- **Gestion des formats de données :** Lecture de formats compressés (ZIP, GZ) directement en Python sans extraction sur disque, via zipfile et gzip.
- **Harmonisation de référentiels :** Application des jointures multi-sources avec pandas et SQLite, notamment la gestion des codes ISO hétérogènes entre HCR (ISO-3) et Eurostat (ISO-2), avec le cas particulier de la Grèce codée EL dans Eurostat.
- **Statistiques descriptives :** Construction d'un taux pondéré par le volume pour des agrégations équitables, distinction entre corrélation de Pearson et Spearman selon la distribution des données.
- **Visualisation :** Production de visualisations multi-axes (twinx), heatmaps annotées et nuages de points étiquetés avec matplotlib et seaborn.

Compétences métiers

- **Domaine de l'asile :** Compréhension approfondie des mécanismes d'asile européens, du rôle du RAEC, et des divergences entre pratiques nationales malgré le cadre juridique commun.
- **Données institutionnelles :** Maîtrise des sources de données institutionnelles (UNHCR, Eurostat, EM-DAT) : formats, couverture, limites, conditions de réutilisation.
- **Communication des résultats :** Capacité à relier des résultats statistiques à des recommandations politiques concrètes destinées à des décideurs non techniques.

Sources et références

Sources de données

#	Source	Données	URL
1	**UNHCR Refugee Data Finder**	Décisions d'asile, demandes, population (2000–2025)	*data.unhcr.org*
2	**Eurostat – NAMA_10_PC**	PIB par habitant en EUR courants (1975–2025)	*ec.europa.eu/eurostat*
3	**Eurostat – NAMA_10_GDP**	PIB total en volumes chaînés et prix courants	*ec.europa.eu/eurostat*
4	**EM-DAT / CRED (UCLouvain)**	Catastrophes naturelles et technologiques mondiales	*emdat.be*
5	**Eurostat – Migration & Asylum**	Statistiques officielles sur les demandes d'asile en Europe	*ec.europa.eu/eurostat*

Publications scientifiques et rapports institutionnels

#	Référence complète

1	*Carammia, M., Iacus, S. M., & Super, L. (2022). Forecasting asylum-related migration flows with machine learning and data at scale. Scientific Reports, 12(1), 1568. https://www.nature.com/articles/s41598-022-05241-8*
2	*Eurostat (2025). Migration and asylum in Europe – 2025 edition. Commission européenne. https://ec.europa.eu/eurostat/web/interactive-publications/migration-2025*
3	*Eurostat (2025). Asylum decisions – annual statistics. Statistics Explained. https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Asylum_decisions_-_annual_statistics*
4	*Bosco, C. (2024). Forecasting migration flows with machine learning. Présentation JRC, INFORM Workshop. Commission européenne. https://drmkc.jrc.ec.europa.eu*
5	*Adenuga et al. (2025). Real-Time Analytics Dashboards for Decision-Making Using Tableau in Public Sector and Business Intelligence Applications. ResearchGate. https://www.researchgate.net/publication/393907578*

Outils et environnement technique

Outil / Librairie	Usage	Version
Python 3.11	Langage principal du projet	3.11.x
pandas	Manipulation des données (DataFrames)	2.2.3
numpy	Calculs numériques et droites de tendance	1.26.4
matplotlib	Création des graphiques (barplot, scatter, courbe)	3.9.2
seaborn	Heatmap et graphiques statistiques	0.13.2
scipy	Corrélations de Pearson et Spearman	1.13.1
sqlite3	Base de données relationnelle légère	Inclus Python
openpyxl	Lecture des fichiers Excel (.xlsx)	3.1.5
VSCode + Jupyter	Environnement de développement	–

Annexes

Annexe 1 — Carammia, M., Iacus, S. M., & Super, L. (2022) — Machine Learning et flux d'asile

Carammia, M., Iacus, S. M., & Super, L. (2022). Forecasting asylum-related migration flows with machine learning and data at scale. Scientific Reports, 12(1), 1568. https://www.nature.com/articles/s41598-022-05241-8. Publication scientifique de référence sur l'application du machine learning aux données d'asile européennes. Justifie l'intégration de variables relatives aux conflits africains (données ACLED) pour tester l'hypothèse H2.

Annexe 2 — Eurostat (2025) — Migration and asylum in Europe, édition 2025

Eurostat (2025). Migration and asylum in Europe – 2025 edition. Commission européenne. https://ec.europa.eu/eurostat/web/interactive-publications/migration-2025. Publication statistique officielle, principale source de données quantitatives pour le projet. Inclut les données sur les décisions d'asile, les demandeurs, les bénéficiaires d'une protection pour tous les États membres.

Annexe 3 — Eurostat (2025) — Asylum decisions, annual statistics

Eurostat (2025). Asylum decisions – annual statistics. Statistics Explained. https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Asylum_decisions_-_annual_statistics. Base de données détaillée sur les décisions d'asile en première instance et en appel, par État membre, par nationalité d'origine et par type de protection accordée.

Annexe 4 — JRC / Bosco (2024) — Forecasting migration flows with machine learning

Bosco, C. (2024). Forecasting migration flows with machine learning. Présentation JRC / Commission européenne, INFORM Workshop. https://drmkc.jrc.ec.europa.eu. Rapport technique du Centre commun de recherche (JRC) sur les modèles de prévision migratoire fondés sur le machine learning.

Annexe 5 — Adenuga et al. (2025) — Dashboards BI dans le secteur public

Adenuga et al. (2025). Real-Time Analytics Dashboards for Decision-Making Using Tableau in Public Sector and Business Intelligence Applications. ResearchGate. https://www.researchgate.net/publication/393907578. Article académique sur l'utilisation des outils de dataviz dans la prise de décision publique.